

Université Paris Cité
Master 2 – Modélisation Aléatoire

Mémoire de stage

Modélisation du Default Risk Charge

*Calibration comparée des sensibilités factorielles
et application à un portefeuille d'actifs du CAC 40*

Auteur : **Franck Deba**
Tuteur de stage : **Pierre Paraire**
Année universitaire : **2025–2026**

Table des matières

Resume	2
Remerciements	3
Introduction generale	4
1 Cadre réglementaire et revue de la littérature	6
1.1 Définitions	6
1.2 Propriétés attendues d'un modèle interne de DRC	8
1.3 État de l'art	8
1.4 Positionnement de la démarche retenue	10
2 Modèle DRC et calibration de la structure de dépendance des défauts	12
2.1 Le modèle factoriel	12
2.2 Calibration par ACP itérative	13
2.3 Calibration par minimisation de la norme de Frobenius	15
2.4 Calibration par le critère du maximum de vraisemblance	16
2.5 Comparaison des trois méthodes	18
3 Application	20
3.1 Données	20
3.2 Calibration du modèle factoriel	22
3.3 Estimation du DRC	26
4 Discussion	29
4.1 Le critère de calibration	29
4.2 Le DRC estimé	30
4.3 Limites	32
4.4 Perspectives	33
Conclusion générale	34
A Annexes	38
A.1 Compléments théoriques	38
A.2 Résultats empiriques complémentaires	43

Resume

Le *Default Risk Charge* (DRC), introduit par la réforme *Fundamental Review of the Trading Book*, dépend étroitement de la structure de corrélation des défauts calibrée au sein d'un modèle gaussien multifactoriel. Trois méthodes de calibration de cette structure sont comparées sur un portefeuille équilibré de 37 émetteurs du CAC 40 : l'analyse en composantes principales itérative (ACP), la minimisation de la norme de Frobenius à la corrélation empirique, et le maximum de vraisemblance du modèle, cette dernière approche n'ayant pas, à notre connaissance, été appliquée à la calibration du DRC dans la littérature existante.

L'ACP itérative et la minimisation de Frobenius fournissent des résultats quasi-identiques sur trois fenêtres de calibration contrastées (crise 2008, période médiane 2013-2014, crise sanitaire 2020-2021). Le maximum de vraisemblance, résolu par le même algorithme d'optimisation (gradient projeté spectral), réussit à reproduire des corrélations élevées que les deux autres méthodes sous-estiment, un écart concentré sur le sous-groupe des quatre émetteurs financiers du portefeuille et cohérent avec la géométrie de pénalisation de la divergence de Kullback-Leibler, à laquelle la maximisation de la vraisemblance est mathématiquement équivalente.

Sur les six configurations testées pour la calibration de la structure de corrélation (modèles à 2 ou 3 facteurs, avec et sans shrinkage de Ledoit et Wolf), le DRC estimé par Monte-Carlo est identique entre les trois méthodes de calibration dans cinq cas sur six ; ceci tient davantage du manque de granularité du portefeuille, la perte agrégée ne prenant que 38 valeurs possibles, que d'un réel désaccord entre méthodes, à l'exception de la période 2020-2021 sous shrinkage à deux facteurs, où le maximum de vraisemblance produit un DRC supérieur de 3 points à celui de l'ACP et de Frobenius. Le critère de Marchenko-Pastur, appliqué indépendamment des trois méthodes de calibration, identifie deux facteurs statistiquement significatifs sur les trois fenêtres retenues, cohérent avec le nombre de facteurs systémiques prescrit par la CRR3.

Mots-clés : Default Risk Charge, FRTB, modèle multifactoriel, corrélation de défaut, maximum de vraisemblance, Marchenko-Pastur, CAC 40.

Remerciements

Mes remerciements vont à l'équipe ALM de PwC, qui m'a accueilli pendant la durée de mon stage, et en particulier à **Pierre Paraire**, mon tuteur de stage, pour son accompagnement, sa disponibilité et la pertinence de ses conseils méthodologiques, qui ont largement nourri l'élaboration de ce mémoire.

Introduction generale

Contexte

La crise financière de 2008 a mis en évidence les limites des dispositifs prudentiels appliqués au portefeuille de négociation, en particulier leur incapacité à rendre compte correctement des pertes liées à des événements de crédit rares mais sévères. Plusieurs établissements ont ainsi subi des pertes très largement supérieures à celles anticipées par les mesures usuelles de risque de marché. Une première réponse réglementaire a été apportée dès 2009 dans le cadre de Bâle 2.5 [BCBS, 2009a,b], avec l'introduction de l'*Incremental Risk Charge* (IRC), destinée à mieux prendre en compte le risque de défaut et de migration de crédit au sein du portefeuille de négociation.

La réforme plus récente du cadre de marché, connue sous le nom de *Fundamental Review of the Trading Book* (FRTB), remplace l'IRC par le *Default Risk Charge* (DRC). Le DRC vise à capter, sur un horizon d'un an, les pertes issues du défaut des positions du portefeuille de négociation, indépendamment des autres composantes du risque de marché [BCBS, 2016, 2019].

Problématique

La modélisation du DRC dans le cadre réglementaire doit répondre à un certain nombre d'attentes du superviseur sur le plan méthodologique. Le régulateur préconise l'utilisation de modèles multifactoriels calibrés sur des données historiques de cours d'actions ou de spreads de CDS des obligors, en s'assurant que le modèle reproduise la corrélation observée sur ces données [European Commission, 2024, European Central Bank, 2025]. Dans la littérature existante, la calibration de la structure de corrélation des modèles factoriels est effectuée par des méthodes de régression économétrique, lorsque les facteurs sont exogènes, par une analyse en composantes principales, ou par une mesure de distance euclidienne entre la corrélation du modèle et la corrélation empirique [Laurent et al., 2016, Slime, 2022, Joseph, 2023].

Objectif

Ce mémoire cherche à répondre à une question simple. Le choix de la méthode de calibration des sensibilités factorielles affecte-t-il la structure de corrélation reconstruite et la mesure du DRC, sur un modèle gaussien multifactoriel ? Trois méthodes sont comparées pour y répondre : l'analyse en composantes principales itérative, la minimisation d'une

distance de Frobenius à la corrélation empirique, et le maximum de vraisemblance du modèle. Cette dernière approche n'a pas, à notre connaissance, fait l'objet d'une étude antérieure dans la littérature autour de la modélisation du DRC. Elle constitue, à ce titre, un apport aux méthodes usuelles de calibration.

Plan du mémoire

Notre travail se décline en quatre chapitres. Le premier pose le cadre réglementaire du DRC et retrace la filiation des modèles de défaut, de Merton au cadre multifactoriel ; il se réfère sur une revue de trois travaux récents, qui situent la contribution propre de ce mémoire. Le deuxième présente le modèle multifactoriel et développe les trois méthodes de calibration comparées, avec un accent particulier sur l'approche introduite, le maximum de vraisemblance. Le troisième applique ces méthodes à un portefeuille équilibré de 37 émetteurs du CAC 40 et simule le DRC correspondant. Le quatrième discute les résultats obtenus, à la lumière du cadre réglementaire et de la littérature. Les développements mathématiques sont renvoyés en annexe dans le souci de rendre la lecture fluide.

Chapitre 1

Cadre réglementaire et revue de la littérature

La crise de 2008 a montré que les mesures de risque alors en vigueur ne captaient pas correctement le risque de crédit porté par le portefeuille de négociation, un angle mort que l'Incremental Risk Charge, puis le Default Risk Charge (DRC) introduit par la réglementation bâloise, vient corriger. Ce chapitre situe le cadre réglementaire du DRC et dresse l'état de l'art de la littérature portant sur sa modélisation.

1.1 Définitions

Le Capital Requirements Regulation (CRR3) définit le périmètre d'applicabilité du DRC aux positions de portefeuille de négociation sensible au risque de crédit : ceci comprend les positions sur obligations, actions, dérivés de crédit [European Commission, 2024]. Pour chaque position, la perte potentielle en cas de défaut, appelée *jump-to-default* (JTD), correspond à la perte de valeur immédiate si l'émetteur fait défaut.

Dans le cadre de ce mémoire, nous limitons notre étude au cas particulier d'un portefeuille de positions sur actions.

1.1.1 Modèle de DRC

Soit un portefeuille de K positions sur actions. La perte à horizon d'une période s'écrit

$$L = \sum_{k=1}^K L_k, \quad L_k = JTD_k \times LGD_k \times D_k, \quad (1.1)$$

où, pour chaque position k :

- JTD_k (*Jump to Default*) est la valeur nominale de la position ;
- LGD_k (*Loss Given Default*)¹ est la part non recouvrée de JTD_k ;
- $D_k = \mathbb{1}_{\{k \text{ fait défaut}\}}$ est l'indicatrice de défaut.

1. Pour les actions, le texte réglementaire retient par convention un taux de recouvrement nul, soit $LGD = 100\%$ [European Commission, 2024] pour l'approche standard. Nous maintenons cette valeur dans le cas spécifique de positions sur actions, notre travail étant orienté sur la calibration de la structure de corrélation. Dans une étude postérieure, on pourra affiner la modélisation du DRC en considérant un modèle de LGD.

Le DRC dans les modèles internes est défini par le régulateur comme le quantile à 99,9 % de la perte, sur un horizon d'un an, à l'image de l'approche IRB retenue en portefeuille bancaire pour le calcul de la charge en capital réglementaire au titre du risque de crédit [European Commission, 2024] :

$$DRC = VaR_{99,9\%}^{1 \text{ an}}(L) = \inf\{q \in \mathbb{R} : \mathbb{P}(L \leq q) \geq 0,999\}. \quad (1.2)$$

La connaissance de la distribution de la perte L permettrait de retrouver directement le DRC. En considérant les LGD_k déterministes, l'expression de L comme somme de variables aléatoires discrètes est triviale ; toute la difficulté de modélisation tient dans la loi jointe du vecteur $(D_1, \dots, D_K)$.

1.1.2 Des modèles à facteur unique au cadre multifactoriel

Pour une position sur action, le défaut survient lorsque la valeur des actifs de l'émetteur devient inférieure à sa dette. Autrement dit, la solvabilité de l'émetteur passe sous un seuil :

$$D_k = \mathbb{1}_{\{X_k \leq c_k\}}. \quad (1.3)$$

où la variable X_k reflète la solvabilité.

Les modèles de risque de crédit s'inscrivent dans la continuité du modèle de Merton [1974], qui considère plus généralement que les actionnaires détiennent une option d'achat sur les actifs de l'entreprise. Le défaut correspond au cas où cette option finit hors la monnaie. Cette construction repose sur une dynamique complète de la valeur des actifs. Dans les applications de portefeuille, on la simplifie : seule la variable terminale de solvabilité est retenue, sans modéliser la trajectoire entre la date d'évaluation et l'échéance.

Le modèle à un facteur de Vasicek [2002] reprend cette simplification en postulant que la solvabilité X_k est influencée par deux éléments : un facteur systémique commun au marché et un facteur idiosyncratique propre à l'émetteur.

$$X_k = \sqrt{\rho_k} Z + \sqrt{1 - \rho_k} \varepsilon_k, \quad Z, \varepsilon_k \sim \mathcal{N}(0, 1) \text{ indépendants}. \quad (1.4)$$

Z représente l'état général de l'économie, ε_k le risque propre à l'émetteur k , et ρ_k sa sensibilité au facteur commun. Le défaut survient lorsque $X_k \leq \Phi^{-1}(p_k)$, p_k étant la probabilité de défaut marginale de l'émetteur.

Pour le DRC en revanche, le passage à un cadre multifactoriel est imposé directement par la CRR3 [European Commission, 2024]. Celle-ci préconise de considérer un modèle à deux facteurs : au facteur de marché s'ajoute, par exemple, un facteur régional ou sectoriel. Chaque émetteur doit avoir une sensibilité non nulle à au moins un facteur de chaque type.

Le régulateur laisse la possibilité aux banques de considérer des facteurs statistiques

latents, ou des facteurs exogènes économiques, du moment que la discipline de validation décrite par [European Central Bank \[2025\]](#) est respectée.

1.2 Propriétés attendues d'un modèle interne de DRC

Les textes de supervision [[European Central Bank, 2025](#)] demandent que la structure de dépendance retenue soit justifiée, documentée et testée. Cela concerne : la justification de la structure de dépendance retenue, la période sur laquelle cette structure est calibrée, la stabilité de l'estimation obtenue par simulation, et un ensemble de contraintes opérationnelles sur le calcul.

- La corrélation n'est pas un simple paramètre d'entrée. C'est un choix de modélisation que l'établissement doit pouvoir défendre, portant sur le choix des facteurs, leur granularité, leurs pondérations, et la corrélation entre eux. Les corrélations de défaut doivent reposer sur des données objectives, qu'il s'agisse d'écarts de crédit ou de cours d'actions [[European Central Bank, 2025](#), §134]. La validation attendue doit comparer explicitement la corrélation implicite du modèle interne à celle qui ressort directement des données de marché.
- Pour le risque de marché général, la période de stress à utiliser dans l'approche par modèles internes est celle, sur une fenêtre continue de douze mois, qui maximise la perte attendue partielle (*partial expected shortfall*) calculée sur un sous-ensemble réduit de facteurs de risque expliquant au moins 75 % de la variance de la perte attendue complète [[European Commission, 2024](#)].
- Estimer un quantile aussi extrême que celui qui définit le DRC, par simulation, demande un grand nombre de tirages. Le superviseur attend que les banques utilisant des modèles internes démontrent la stabilité de leur estimation, et peut demander un intervalle de confiance à 95 % autour du DRC [[European Central Bank, 2025](#), §128-129].
- Le calcul repose sur l'hypothèse d'une position constante sur un horizon de liquidité d'un an [[European Commission, 2024](#)] : le portefeuille est figé à la date d'évaluation, seule la survenance des défauts est simulée sur l'année suivante. Enfin, la CRR3 impose un recalcul hebdomadaire minimum du DRC lorsqu'il repose sur un modèle interne [[European Commission, 2024](#)].

1.3 État de l'art

Une fois le cadre multifactoriel posé, une question reste ouverte. Comment calibrer, à partir de données observées, les sensibilités des émetteurs aux facteurs systémiques ? Les travaux sur cette modélisation sont récents et restent d'actualité.

1.3.1 Laurent, Sestier et Thomas (2016)

Pionniers de la modélisation du DRC, [Laurent et al. \[2016\]](#) étudient l'implication pratique de l'exigence bâloise d'un modèle à deux facteurs. Ils testent la sensibilité du DRC à des matrices de corrélation cibles construites à partir de sources différentes : rendements actions, spreads de CDS, méthodologie propriétaire GCorr de Moody's KMV, formule IRB, et facteurs exogènes issus d'indices MSCI. Cette diversité de sources fait écho à l'exigence de justification quantitative rappelée en section 1.2. Le choix de la source de calibration n'est pas neutre, et le DRC obtenu varie sensiblement selon la source retenue.

Les auteurs s'écartent explicitement des recommandations sur l'historicité et la granularité des données de calibration prescrites par le texte réglementaire [[BCBS, 2016](#), [European Commission, 2024](#), [European Central Bank, 2025](#)]. Ce dernier recommande de calibrer les corrélations sur un historique de dix ans, en utilisant des co-mouvements annuels, ce qui ne fournit que dix observations par paire d'actifs. [Wilkins and Predescu \[2016\]](#) montrent que cette prescription induit un bruit d'estimation considérable, sous la forme d'intervalles de confiance très larges autour de chaque corrélation estimée, précisément du fait de ce nombre d'observations restreint. [Laurent et al. \[2016\]](#) leur préfèrent des rendements journaliers sur une seule fenêtre d'un an, choisie au sein de cette période de dix ans comme fenêtre de stress, ce qui porte la taille de leur panel, de dix observations sous la méthodologie prescrite par [BCBS \[2016\]](#), à environ deux cent cinquante sous la leur. Un gain de granularité statistique, non de durée d'historique.

Une fois la corrélation cible fixée, les auteurs comparent deux méthodes pour calibrer la corrélation implicite du modèle : une analyse en composantes principales (ACP) itérative, et une minimisation directe de l'écart quadratique à la corrélation empirique sous contrainte, résolue par l'algorithme du gradient projeté spectral (SPG).

Leur étude révèle que contraindre le modèle à exactement deux facteurs ne réduit pas la variabilité des actifs pondérés du risque selon la source de calibration, et peut même conduire à sous-estimer le risque par rapport à des modèles à plus de facteurs. Ce résultat justifie d'explorer des structures à plus de deux facteurs.

1.3.2 Slime (2022)

[Slime \[2022\]](#) développe un cadre DRC complet, mêlant positions de crédit et actions. Il modélise également la perte en cas de défaut pour tenir compte de sa variabilité. La structure factorielle retenue spécifie quatre types de facteurs (global, actif, région, secteur), rendus indépendants par une orthogonalisation séquentielle de Gram-Schmidt. L'auteur propose deux méthodes pour quantifier la concentration : un indice de Herfindahl-Hirschman ajusté aux positions longues et courtes, et un ajustement de granularité inspiré de [Pykhtin \[Pykhtin, 2004\]](#). La comparaison entre DRC simulé et approximation analytique montre un écart très faible, ce qui valide l'approximation. L'auteur reconnaît que le choix de la

copule gaussienne et de l'approche structurelle de Merton reste discutable.

1.3.3 Joseph (2023)

Joseph [2023] applique le DRC à un marché émergent, l'Afrique du Sud, choisi pour son exposition sectorielle marquée et la rareté de ses données de crédit. Il critique la méthode d'extraction par décomposition spectrale : les vecteurs propres obtenus s'interprètent difficilement en termes économiques, ce qui complique l'analyse de concentration par émetteur. Il propose à la place, en s'appuyant sur Wilkens and Predescu [2016], une construction à trois facteurs exogènes : global, pays, industrie. Ces facteurs s'obtiennent par régressions emboîtées, chacune isolant la part de rendement non expliquée par les facteurs déjà extraits.

1.4 Positionnement de la démarche retenue

Laurent et al. [2016] comparent deux approches de calibration dont le critère commun est l'écart entre la matrice de corrélation empirique et la matrice de corrélation implicite d'un modèle multifactoriel. Sous l'hypothèse de gaussianité, cet écart suffit à caractériser la distribution des événements de défaut et, par suite, à calibrer le DRC. Joseph [2023] et Slime [2022] partent, quant à eux, de facteurs exogènes et calibrent les sensibilités du modèle multifactoriel par régression linéaire, à quelques transformations près. Cette approche ne tient pas compte de la forme de la variance de la composante idiosyncratique et ne la teste pas statistiquement. Elle est ensuite imposée au stade de la simulation, jamais dans la calibration elle-même. Certes, cette dernière approche est utile pour des besoins d'interprétation économétrique, mais l'est moins pour la simulation du DRC.

Ces trois travaux, bien que reposant sur des méthodes distinctes (minimisation d'une distance entre corrélations pour Laurent et al., régression linéaire sur facteurs exogènes ou orthogonalisés pour Joseph et Slime), partagent une même limite : aucun ne calibre les paramètres du modèle au regard de sa structure probabiliste complète. Or c'est bien sous cette distribution, gaussienne dans les trois cas, qu'est en définitive estimé le DRC par simulation de Monte Carlo. La calibration procède ainsi par ajustement à une cible calculée à part (corrélations empiriques, facteurs exogènes) plutôt que par exploitation directe de la vraisemblance du modèle sous-jacent.

Ce mémoire se positionne dans l'espace laissé ouvert par ces travaux. Il compare, sur un même portefeuille, trois méthodes de calibration : l'ACP itérative, la minimisation de l'écart entre la corrélation empirique et la corrélation implicite du modèle, et le maximum de vraisemblance du modèle. Les deux premières méthodes prolongent directement l'approche de Laurent et al. [2016]. La troisième constitue l'apport propre du mémoire : en substituant à une distance calculée à part un critère fondé sur la vraisemblance gaussienne

du modèle, elle exploite directement la structure probabiliste qui gouverne, par ailleurs, l'estimation du DRC par simulation.

Chapitre 2

Modèle DRC et calibration de la structure de dépendance des défauts

Dans ce chapitre, on explore trois méthodes pour calibrer la structure de dépendance des événements de défaut inhérents au DRC. Les deux premières, héritées de la littérature : décomposition spectrale de la corrélation empirique, et minimisation de la distance de la matrice de corrélation implicite à la matrice de corrélation empirique. La troisième approche adopte pour critère la vraisemblance des observations.

Sauf indication contraire, les facteurs systémiques considérés ne sont pas exogènes. Nous faisons le choix de facteurs statistiques comme le permettent les textes réglementaires au sujet du DRC [BCBS, 2016, European Commission, 2024, European Central Bank, 2025].

2.1 Le modèle factoriel

On considère un portefeuille de K actifs observés sur T dates, et un nombre $J < K$ de facteurs de risque. Les rendements standardisés $X_t \in \mathbb{R}^K$ ($t = 1, \dots, T$) suivent

$$X_t = \beta Z_t + \sigma(\beta) \varepsilon_t, \quad Z_t \sim \mathcal{N}(0, \Sigma_Z), \quad \varepsilon_t \sim \mathcal{N}(0, I_K), \quad Z_t \perp \varepsilon_t, \quad (2.1)$$

où $\beta \in \mathbb{R}^{K \times J}$ est la matrice des sensibilités ($\beta_k \in \mathbb{R}^J$ sa k -ième ligne), Σ_Z la covariance des facteurs, et $\sigma(\beta) = D(\beta)^{1/2}$.

Pour que chaque rendement conserve une variance unitaire, le modèle impose

$$D(\beta) = \text{diag}(\sigma_1^2(\beta), \dots, \sigma_K^2(\beta)), \quad \sigma_k^2(\beta) = 1 - \beta_k^\top \Sigma_Z \beta_k, \quad k = 1, \dots, K. \quad (2.2)$$

Cette contrainte a une conséquence importante. La variance spécifique $\sigma_k^2(\beta)$ n'est pas un paramètre libre. Elle est entièrement déterminée par les sensibilités β_k et par Σ_Z , ce dernier étant, dans l'approche retenue ici, une constante fixée et non un argument supplémentaire à ajuster. Elle garantit en outre que la matrice reconstruite ci-dessous demeure une matrice de corrélation valide, semi-définie positive et de diagonale unitaire.

L'importance de cette contrainte réside dans la définition d'un événement de défaut

posée dans le cadre structurel de [Merton \[1974\]](#) :

$$D_k = \mathbb{1}_{\{X_k \leq c_k\}} \quad \text{avec} \quad c_k = \Phi^{-1}(p_k). \quad (2.3)$$

La matrice de corrélation implicite du modèle s'écrit

$$\Sigma_X(\beta) := \beta \Sigma_Z \beta^\top + \text{diag}\left(1 - \text{diag}(\beta \Sigma_Z \beta^\top)\right), \quad (2.4)$$

de diagonale toujours égale à 1 par construction. C'est cette matrice que l'on cherche à rapprocher de la corrélation empirique $C_0 = \frac{1}{T} X^\top X$, conformément à l'exigence de validation quantitative rappelée en section 1.2.

2.2 Calibration par ACP itérative

Dans cette section $\Sigma_Z = I_J$. Ceci tient de ce que, par construction, les facteurs issus de l'ACP sont orthogonaux.

2.2.1 Motivation

La partition $(\Gamma_J, \Gamma_{\bar{J}})$ de la matrice orthogonale Γ diagonalisant C_0 selon les J premiers axes principaux et les $K - J$ restants induit une partition duale du vecteur des composantes principales $Y = \Gamma^\top X$. En considérant les J premiers vecteurs propres comme les sensibilités factorielles et les J premières composantes principales comme les facteurs, on obtient un modèle à J facteurs dont les résidus portent le reste du spectre. [Andersen et al. \[2003\]](#) montrent que cette construction, bien que naturelle, ne peut être obtenue par une simple troncature de la décomposition spectrale de C_0 .

La structure factorielle spécifiée par l'équation (2.2) impose une variance résiduelle $D(\beta)$ qui dépend de β lui-même, alors qu'une troncature brute de C_0 traite implicitement toute la variance de chaque actif comme expliquée par les facteurs communs, sans laisser de place à cette variance spécifique. L'algorithme d'ACP itérative proposé par [Andersen et al.](#), dans le contexte des paniers de crédit, corrige cet inconvénient. [Laurent et al. \[2016\]](#) reprennent cette approche de calibration dans le contexte du DRC sur un panier d'actions.

2.2.2 Algorithme et propriétés

À chaque itération i , connaissant une estimation courante $\sigma^2(\beta_i)$ de la variance spécifique, on diagonalise la matrice réduite

$$C_0 - \text{diag}\left(\sigma^2(\beta_i)\right) = \Gamma_i \Lambda_i \Gamma_i^\top,$$

identique à C_0 hors diagonale, et l'on pose $\beta_{i+1} = \Gamma_{i,J} \Lambda_{i,J}^{1/2}$, où $\Gamma_{i,J}$ et $\Lambda_{i,J}$ regroupent les J plus grands vecteurs et valeurs propres de cette matrice réduite. On met alors à jour $\sigma^2(\beta_{i+1}) = 1 - \text{diag}(\beta_{i+1} \beta_{i+1}^\top)$ et l'on répète jusqu'à ce que $\sigma^2(\beta_{i+1})$ soit suffisamment proche de $\sigma^2(\beta_i)$.

L'itération initiale ($m = 0$), $\sigma^2(\beta_0) = 0$, redonne directement la décomposition spectrale de C_0 , avant toute correction de la diagonale. C'est le point de départ naturel de l'algorithme.

Algorithm 1 Facteurs principaux itérés [Thurstone, 1947, Harman, 1976]

```

1: procedure FACTEURSPRINCIPAUXITERES( $C_0, J, \text{tol}$ )
2:    $\hat{h}^{(0)} \leftarrow (1, \dots, 1)$ 
3:    $\tilde{C}^{(0)} \leftarrow C_0$ 
4:    $m \leftarrow 0$ 
5:   repeat
6:     Diagonaliser  $\tilde{C}^{(m)} = \Gamma^{(m)} \text{diag}(\lambda_1^{(m)}, \dots, \lambda_K^{(m)}) \Gamma^{(m)\top}$ ,  $\lambda_1^{(m)} \geq \dots \geq \lambda_K^{(m)}$ 
7:      $\beta^{(m+1)} \leftarrow \Gamma^{(m)} \text{diag}(\lambda_1^{(m)}, \dots, \lambda_K^{(m)})^{\frac{1}{2}}$ 
8:     for  $k = 1 \rightarrow K$  do
9:        $h_k^{(m+1)} \leftarrow (\beta^{(m+1)} \beta^{(m+1)\top})_{kk}$ 
10:      if  $h_k^{(m+1)} > 1 - \varepsilon$  then
11:         $h_k^{(m+1)} \leftarrow 1 - \varepsilon$ 
12:      end if
13:    end for
14:     $\tilde{C}^{(m+1)} \leftarrow C_0 - \text{diag}(1 - h^{(m+1)})$ 
15:     $m \leftarrow m + 1$ 
16:  until  $\|\hat{h}^{(m)} - \hat{h}^{(m-1)}\|_\infty < \text{tol}$ 
17:  return  $\beta^{(m)}$ ,  $\delta^{(m)} \leftarrow 1 - h^{(m)}$ 
18: end procedure

```

Remarque 2.1 (Convergence). Borsdorf et al. [2010] soulignent qu'aucune théorie de convergence ne soutient cette méthode itérative fondée sur l'ACP ; néanmoins, elle produit en pratique de bons résultats, en partie parce que la contrainte $\beta_k^\top \beta_k \leq 1$ n'est souvent pas active à la solution obtenue.

2.3 Calibration par minimisation de la norme de Frobenius

2.3.1 Motivation

Plutôt que de corriger une extraction algébrique par une procédure itérative, cette seconde méthode formule directement la calibration comme un problème d'optimisation sous contrainte. Trouver les sensibilités qui rapprochent le plus possible, au sens de la norme de Frobenius, la corrélation implicite du modèle de la corrélation empirique C_0 .

2.3.2 Programme et propriétés

Le problème posé s'écrit comme suit

$$\begin{cases} \arg \min_{\beta \in \Omega} \|C_0 - \Sigma_X(\beta)\|_F \\ \Omega = \{\beta \in \mathbb{R}^{K \times J} : \beta_k^\top \Sigma_Z \beta_k \leq 1, \ k = 1, \dots, K\}, \end{cases} \quad (2.5)$$

où $\|\cdot\|_F$ désigne la norme de Frobenius, $\|A\|_F = \sqrt{\text{tr}(A^\top A)}$. La contrainte $\beta_k^\top \Sigma_Z \beta_k \leq 1$ garantit que la variance spécifique implicite reste positive ou nulle, et que la matrice reconstruite demeure semi-définie positive.

En pratique, on minimise la fonction objectif équivalente

$$f(\beta) = \|C_0 - \Sigma_X(\beta)\|_F^2 = \text{tr}[(C_0 - \Sigma_X(\beta))^\top (C_0 - \Sigma_X(\beta))], \quad (2.6)$$

et non $\|C_0 - \Sigma_X(\beta)\|_F$ elle-même. La norme au carré (2.6) et la norme (2.5) partagent exactement le même argument minimisant.

Deux propriétés découlent immédiatement :

- **Existence** : Ω est convexe et compact, une intersection de boules fermées et bornées, et l'objectif f défini en (2.6) est continue, voire de classe C^1 sur Ω . Un minimiseur global existe donc toujours ;
- **Non-unicité** : ce minimiseur n'est pas unique. Pour toute matrice orthogonale Q , telle que $Q^\top Q = I_J$, β et βQ atteignent la même valeur du critère, puisque $\beta Q (\beta Q)^\top = \beta \beta^\top$. Le groupe de ces transformations est donc, dans le cas $\Sigma_Z = I_J$ retenu ici, le groupe orthogonal complet $O(J)$, infini dès que $J \geq 2$.

Le programme équivalent à (2.5) (en remplaçant l'objectif par (2.6)) est résolu, dans ce mémoire comme chez [Laurent et al. \[2016\]](#), par l'algorithme du gradient projeté spectral (SPG) de [Birgin et al. \[2001\]](#). Pour cela, nous utilisons la forme explicite du gradient de f :

$$\nabla f(\beta) = 4(\Sigma_X(\beta) - C_0) \beta \Sigma_Z.$$

2.4 Calibration par le critère du maximum de vraisemblance

2.4.1 Motivation et cadre probabiliste

Le critère du maximum de vraisemblance maximise la vraisemblance exacte du modèle marginal en X , obtenue en intégrant explicitement le facteur latent Z hors de la loi jointe (X_t, Z_t) posée par le modèle (2.1).

Le modèle (2.1) porte sur le couple (X_t, Z_t) . Dans le cas où l'on disposerait de facteurs exogènes Z_t , on peut établir la vraisemblance des observations complètes (X_t, Z_t) . En l'absence de facteurs exogènes, on préfère la vraisemblance des observations X_t .

2.4.2 Vraisemblance des données : en présence de facteurs exogènes

Elle porte sur le modèle complet défini par (2.1). La densité jointe de (X_t, Z_t) se factorise en une densité conditionnelle et une densité marginale du facteur exogène :

$$p(X_t, Z_t; \beta) = \underbrace{p(X_t | Z_t; \beta)}_{\text{loi de } X_t | Z_t, \text{ cf. (2.1)}} \times \underbrace{p(Z_t)}_{\text{loi de } Z_t, \text{ cf. (2.1)}}. \quad (2.7)$$

Le premier facteur découle directement de $X_t = \beta Z_t + \sigma(\beta) \varepsilon_t$, soit $X_t | Z_t \sim \mathcal{N}(\beta Z_t, D(\beta))$. Le second est l'hypothèse $Z_t \sim \mathcal{N}(0, \Sigma_Z)$ du modèle. En sommant les logarithmes de (2.7) sur les T observations, on obtient la log-vraisemblance des données complètes :

$$\ell_c(\beta) := \underbrace{-\frac{1}{2} \sum_{t=1}^T \left[\log |D(\beta)| + (X_t - \beta Z_t)^\top D(\beta)^{-1} (X_t - \beta Z_t) \right]}_{\sum_t \log p(X_t | Z_t; \beta)} - \underbrace{\frac{T}{2} \log |\Sigma_Z| - \frac{1}{2} \sum_{t=1}^T Z_t^\top \Sigma_Z^{-1} Z_t}_{\sum_t \log p(Z_t)} + \text{cste.} \quad (2.8)$$

Le second groupe de termes ne dépend pas de β .

2.4.3 Vraisemblance des données : en l'absence de facteurs exogènes

C'est la vraisemblance du même modèle, mais exprimée uniquement en fonction des données réellement disponibles, $X_1, \dots, X_T$. Elle s'obtient en intégrant ℓ_c par rapport à la loi de Z_t , ce qui revient à ne conserver que la loi marginale de X_t . Sous le modèle (2.1), $X_t \sim \mathcal{N}(0, \Sigma_X(\beta))$, d'où, en développant explicitement la densité gaussienne multivariée,

$$\ell(\beta) = -\frac{T}{2} \left[K \log(2\pi) + \log |\Sigma_X(\beta)| + \frac{1}{T} \sum_{t=1}^T X_t^\top \Sigma_X(\beta)^{-1} X_t \right]. \quad (2.9)$$

C'est la fonction ℓ qui constitue l'objectif statistique de cette section¹. C'est elle que l'on cherche à maximiser en β , puisqu'elle est la seule à porter sur les données effectivement observées.

L'équation (2.9) se réécrit donc de façon strictement équivalente

$$\ell(\beta) = -\frac{T}{2} \left[K \log(2\pi) + \log |\Sigma_X(\beta)| + \text{tr}(\Sigma_X(\beta)^{-1} C_0) \right], \quad (2.10)$$

$$= -T \cdot D_{\text{KL}}(\mathcal{N}(0, C_0) \parallel \mathcal{N}(0, \Sigma_X(\beta))) - \underbrace{\frac{T}{2} (K + \log |C_0|) - \frac{TK}{2} \log(2\pi)}_{= \text{cte}', \text{ indépendante de } \beta}. \quad (2.11)$$

où D_{KL} est la mesure de divergence de Kullback-Leibler² utilisée pour comparer deux distributions. Il apparaît que la log-vraisemblance ne dépend de β qu'à travers $\Sigma_X(\beta)$ et $C_0 = \frac{1}{T} X^\top X$: exactement les deux mêmes objets que ceux comparés par le critère de Frobenius (2.6).

2.4.4 Programme d'optimisation et propriétés

La calibration des paramètres est obtenue par résolution du programme

$$\begin{cases} \arg \max_{\beta \in \Omega} \ell(\beta) \\ \Omega = \{\beta \in \mathbb{R}^{K \times J} : \beta_k^\top \Sigma_Z \beta_k < 1, \ k = 1, \dots, K\}. \end{cases} \quad (2.12)$$

Équivalent à

$$\begin{cases} \arg \min_{\beta \in \Omega} D_{\text{KL}}(\mathcal{N}(0, C_0) \parallel \mathcal{N}(0, \Sigma_X(\beta))) \\ \Omega = \{\beta \in \mathbb{R}^{K \times J} : \beta_k^\top \Sigma_Z \beta_k < 1, \ k = 1, \dots, K\}. \end{cases} \quad (2.13)$$

Trois propriétés encadrent cette méthode, en miroir de celles de la section précédente :

- **Non-compacité du domaine strict** : l'espace des paramètres admissibles Ω n'est pas compact³, rien n'empêche en théorie qu'une variance spécifique tende vers zéro le long de la suite des itérés, la pathologie dite de Heywood [Lawley, 1940], plus probable quand T est petit devant $K \times J$. En pratique, imposer un

1. Notre démarche s'appuyant sur une approche de facteurs statistiques non observés, comme le permet le cadre de la CRR3.

2. Pour deux gaussiennes centrées $\mathcal{N}(0, \Sigma_0)$ et $\mathcal{N}(0, \Sigma_1)$ en dimension K , la divergence de Kullback-Leibler est définie par :

$$D_{\text{KL}}(\mathcal{N}(0, \Sigma_0) \parallel \mathcal{N}(0, \Sigma_1)) = \frac{1}{2} \left[\text{tr}(\Sigma_1^{-1} \Sigma_0) - K + \log |\Sigma_1| - \log |\Sigma_0| \right].$$

3. C'est cette absence de compacité qui impose, dans l'implémentation numérique, de relâcher la contrainte $\beta_k^\top \Sigma_Z \beta_k < 1$ en considérant désormais $\beta_k^\top \Sigma_Z \beta_k \leq 1 - \varepsilon$. En effet, au bord exact, $\Sigma_X(\beta)$ devient singulière.

seuil $\sigma_k^2(\beta) \geq \varepsilon > 0$ suffit à obtenir une convergence stable ;

- **Existence sur le domaine relâché** : sur le domaine relâché et fermé $\Omega_\varepsilon = \{\beta : \beta_k^\top \Sigma_Z \beta_k \leq 1 - \varepsilon\}$, $-\ell$ est continûment différentiable, et l'algorithme SPG, appliqué cette fois à $-\ell$, garantit la convergence vers un point stationnaire du problème contraint. La forme explicite du gradient de ℓ est donnée par :

$$\nabla \ell(\beta) = T \left[\Sigma_X(\beta)^{-1} (C_0 - \Sigma_X(\beta)) \Sigma_X(\beta)^{-1} \right]_{\text{off}} \beta \Sigma_Z,$$

où $[\cdot]_{\text{off}}$ est l'opérateur annulant la diagonale de la matrice argument.

- **Non-convexité** : la fonction $-\ell$ n'est pas convexe en β . La convergence vers un point stationnaire ne garantit donc pas qu'il s'agisse d'un minimum global.

2.5 Comparaison des trois méthodes

Critère d'optimisation. Le programme (2.5) minimise l'écart entre C_0 et $\Sigma_X(\beta)$ par une distance euclidienne directe, $\|C_0 - \Sigma_X(\beta)\|_F^2$, terme à terme et symétrique. Le programme (2.12), lui, mesure la divergence entre les distributions sous la corrélation empirique C_0 et sous la corrélation implicite $\Sigma_X(\beta)$ par la divergence de Kullback–Leibler entre les deux lois gaussiennes centrées associées.

Cette divergence, contrairement à une mesure de distance, n'est ni symétrique en ses deux arguments, ni bornée : elle pénalise beaucoup plus sévèrement une sous-estimation de la variance dans une direction où C_0 en porte (le terme $\text{tr}(\Sigma_X(\beta)^{-1} C_0)$ diverge si $\Sigma_X(\beta)$ s'approche de la singularité dans une direction où C_0 ne l'est pas), alors que la distance de Frobenius traite symétriquement les écarts positifs et négatifs, et reste bornée sur tout le domaine Ω . Les deux critères partagent donc le même point de départ (C_0) et le même point d'arrivée recherché ($\Sigma_X(\beta) \approx C_0$), mais n'imposent pas la même géométrie de pénalisation à l'écart entre les deux.

Non-unicité de la solution. La non-unicité des solutions aux programmes (2.5) et (2.12) provient de ce que, étant donné β solution, pour toute matrice orthogonale Q telle que $Q^\top \Sigma_Z Q = \Sigma_Z$, βQ est également solution⁴. Toutefois, la non-unicité n'affecte pas la matrice de corrélation implicite $\Sigma_X(\beta)$, ni la distribution de X . En effet, l'hypothèse de gaussianité de la distribution de Z et de ε garantit que $X \sim \mathcal{N}(0, \Sigma_X(\beta))$, et puisque $\Sigma_X(\beta Q) = \Sigma_X(\beta)$, la distribution reste inchangée. On ne peut cependant pas en tirer une interprétation économétrique de β . De même, l'ACP itérative n'assure pas l'unicité de la solution β , par construction, au signe près des vecteurs propres, lorsqu'elle converge.

4. En particulier, pour $\Sigma_Z = I_J$, toute matrice orthogonale convient.

Estimation de la matrice de corrélation. Les trois méthodes de calibration présentées dans ce chapitre cherchent à reproduire la structure de la matrice cible C_0 au moyen d'un modèle factoriel. Jusqu'ici, C_0 a été identifiée à la corrélation empirique $\hat{C}_0 = \frac{1}{T}X^\top X$. Cet estimateur, bien que sans biais, porte un bruit d'échantillonnage qui s'accroît lorsque T n'est pas très grand devant K [Ledoit and Wolf, 2003].

Le *shrinkage* substitue à $\hat{C}_0$ une combinaison convexe avec une cible structurée F , moins bruitée mais biaisée :

$$C_0^{\text{LW}} = (1 - \delta) \hat{C}_0 + \delta F, \quad \delta \in [0, 1].$$

Ledoit and Wolf [2003] retiennent, pour une matrice de corrélation, le modèle à corrélation constante : F vaut 1 sur la diagonale et la corrélation moyenne $\bar{\rho} = \frac{2}{K(K-1)} \sum_{i < j} (\hat{C}_0)_{ij}$ hors diagonale. Cette cible impose la même corrélation à toute paire d'actifs, une structure plus simple et moins bruitée que $\hat{C}_0$, sans pour autant ignorer entièrement le niveau moyen de dépendance observé dans les données, à la différence d'une cible d'indépendance totale.

Ledoit and Wolf [2003] proposent une intensité optimale, au sens de la minimisation de l'écart quadratique moyen entre C_0^{LW} et la corrélation, inconnue, de la population :

$$\hat{\delta}^* = \max \left\{ 0, \min \left\{ \frac{\hat{\kappa}}{T}, 1 \right\} \right\},$$

où $\hat{\kappa}$ rapporte la somme des variances asymptotiques des éléments de $\sqrt{T} \hat{C}_0$ à l'écart de Frobenius au carré $\|\hat{C}_0 - F\|_F^2$. Nous retenons l'implémentation du module `sklearn.covariance.LedoitWolf`, dont la version retenue ici applique la cible à corrélation constante décrite ci-dessus.

5. `sklearn.covariance.LedoitWolf`, dont la version retenue ici applique la cible à corrélation constante décrite ci-dessus.

Chapitre 3

Application

Ce chapitre calibre le DRC par simulation de Monte-Carlo, à partir de la structure de dépendance des défauts calibrée sous chacune des trois approches présentées au chapitre précédent. Le travail porte sur un portefeuille d’actions du CAC 40 équipondéré. La *LGD* est supposée constante et égale à 100 % pour chaque position, l’objectif poursuivi étant d’isoler l’effet de la méthode de calibration de la corrélation des défauts sur le DRC. Les notations de crédit assignées aux émetteurs sont fictives, ce qui affecte le niveau du DRC simulé mais non la structure de dépendance calibrée, seul objet de la comparaison conduite dans ce chapitre.

3.1 Données

3.1.1 Portefeuille

Le portefeuille regroupe $K = 37$ obligors constituants du CAC 40, chacun affecté de la même pondération $w_k = 1/37$. L’équipondération est exogène à toute estimation statistique, ce qui isole l’effet de la méthode de calibration de celui d’une construction de portefeuille par optimisation. La restriction à ces 37 émetteurs tient à l’exclusion de deux constituants du CAC 40 : Stellantis, dont les cours d’actions obtenus via Yahoo Finance affichent des valeurs nulles sur une partie de l’historique, un artefact de données lié à sa formation par fusion en janvier 2021 ; et Worldline, cotée depuis 2014 seulement, dont l’historique ne couvre pas la fenêtre de crise 2008 retenue ci-dessous.

Chaque émetteur est associé à une notation de crédit fictive, assignée par tranche à défaut d’accès à une source externe de notation réelle, dans le seul but de fournir une probabilité de défaut pour la simulation du DRC.

TABLE 3.1 – Composition du portefeuille par notation

Notation	Nombre de titres	Part du portefeuille	PD à 1 an (plancher CRR3 inclus)
AA	4	10,8 %	3,0 bp
A	16	43,2 %	6,0 bp
BBB	16	43,2 %	17,0 bp
BB	1	2,7 %	65,0 bp
Total	37	100 %	PD moyenne pondérée : 12,03 bp

Un plancher de 3 bp, prescrit par la CRR3 pour l’approche standard [European Commission, 2024], est appliqué à chaque notation.

Quatre émetteurs sont classés financiers (BNP Paribas, Crédit Agricole, Société Générale et AXA), 33 non financiers, ce qui porte l’analyse sectorielle à $\binom{4}{2} = 6$ paires financières contre $\binom{33}{2} = 528$ paires non financières.

3.1.2 Trois fenêtres de calibration

Le texte réglementaire définit précisément, pour le risque de marché général, la période de tension à retenir : celle qui maximise, sur une fenêtre continue de douze mois, la perte attendue partielle calculée sur un sous-ensemble réduit de facteurs de risque [European Commission, 2024]. Dans notre étude, nous ne reprenons pas cette méthodologie. A la place, nous considérons trois périodes : les deux premières reprises de Laurent et al. [2016], et la troisième correspondant à la crise covid.

- Période 1 : la **crise de 2008**, du 7 janvier 2008 au 9 janvier 2009, 261 rendements journaliers ;
- Période 2 : la **période médiane 2013-2014**, du 9 janvier 2013 au 9 janvier 2014, mêmes bornes calendaires, même nombre d’observations ;
- Période 3 : la **période covid**, du 6 janvier 2020 au 6 janvier 2021.

3.1.3 Configurations testées

Les trois méthodes du chapitre 2 sont appliquées sur les trois fenêtres, pour chacune des configurations présentées dans le tableau 3.2. Frobenius et maximum de vraisemblance partagent le même algorithme de résolution, le gradient projeté spectral (Annexe A.1) ; seule la fonction objectif les distingue. L’ACP itérative dispose d’une solution de référence obtenue par diagonalisations successives, sans recours à cet algorithme.

TABLE 3.2 – Configurations de calibration retenues

Configuration	Période	Méthode d'estimation de C_0	Approche de calibration des modèles factoriels
(1) P1	1	Corrélations empiriques	ACP, Norme de Frobenius, log-vraisemblance
(2) P1-shrunked	1	shrinkage ($\hat{\delta}^* = 0,038$)	ACP, Norme de Frobenius, log-vraisemblance
(3) P2	2	Corrélations empiriques	ACP, Norme de Frobenius, log-vraisemblance
(4) P2-shrunked	2	shrinkage ($\hat{\delta}^* = 0,037$)	ACP, Norme de Frobenius, log-vraisemblance
(5) P3	3	Corrélations empiriques	ACP, Norme de Frobenius, log-vraisemblance
(6) P3-shrunked	3	shrinkage ($\hat{\delta}^* = 0,06$)	ACP, Norme de Frobenius, log-vraisemblance

3.2 Calibration du modèle factoriel

3.2.1 Résultats de convergence et d'ajustement

L'ACP itérative et Frobenius convergent vers une erreur de Frobenius identique à la quatrième décimale, sur les trois périodes. Le maximum de vraisemblance atteint un optimum de Frobenius supérieur de moins de 3 % en écart relatif dans toutes les configurations testées. Les temps de calcul restent, pour les trois méthodes, de l'ordre du dixième de seconde ou moins.

TABLE 3.3 – Convergence, log-vraisemblance et qualité d’ajustement de la corrélation

Configuration	Nombre de facteurs	Norme de Frobenius			- Loglik (10^2)		
		ACP	Frob.	MLE	ACP	Frob.	MLE
(1) P1,	2 facteurs	1,38	1,38	1,41	98,63	98,63	98,59
(2) P1-shrunked	3 facteurs	1,19	1,19	1,22	97,55	97,55	97,48
(3) P2,	2 facteurs	1,66	1,66	1,71	110,34	110,34	110,22
(4) P2-shrunked	3 facteurs	1,41	1,41	1,45	109,39	109,39	109,26
(5) P3,	2 facteurs	1,83	1,83	1,97	93,16	93,16	92,57
(6) P3-shrunked	3 facteurs	1,35	1,35	1,45	90,36	90,36	89,86

3.2.2 Corrélation implicite

Le tableau 3.4 ne distingue pas les configurations avec et sans shrinkage : les corrélations moyennes obtenues sous les deux estimateurs de C_0 coïncident à la deuxième décimale, cohérent avec la faible intensité de shrinkage estimée sur les trois fenêtres ($\hat{\delta}^* = 0,037$ à $\hat{\delta}^* = 0,06$, section 2.5).

TABLE 3.4 – Corrélation moyenne implicite, comparée à la cible C_0

Configuration	Nombre de facteurs	Corrélation moyenne			Corrélation moyenne Financier			Corrélation moyenne Non-financier		
		ACP	Frob.	MLE	ACP	Frob.	MLE	ACP	Frob.	MLE
(1) P1, (2) P1-shrunked	C_0	0,53	0,53	0,53	0,72	0,72	0,72	0,53	0,53	0,53
	2 facteurs	0,53	0,53	0,53	0,65	0,65	0,69	0,53	0,53	0,53
	3 facteurs	0,53	0,53	0,53	0,66	0,66	0,69	0,53	0,53	0,53
(3) P2, (4) P2-shrunked	C_0	0,38	0,38	0,38	0,76	0,76	0,76	0,36	0,36	0,36
	2 facteurs	0,38	0,38	0,38	0,69	0,69	0,74	0,36	0,36	0,36
	3 facteurs	0,37	0,37	0,37	0,71	0,71	0,76	0,36	0,36	0,36
(5) P3, (6) P3-shrunked	C_0	0,55	0,55	0,55	0,88	0,88	0,88	0,53	0,53	0,53
	2 facteurs	0,55	0,55	0,55	0,81	0,81	0,88	0,53	0,53	0,53
	3 facteurs	0,55	0,55	0,55	0,84	0,84	0,88	0,53	0,53	0,53

La corrélation moyenne de l'ensemble passe de 0,53 en crise à 0,38 sur la période médiane, quelle que soit la méthode. La figure 3.1 donne à voir cette structure paire par paire, sous corrélation empirique ; la figure 3.2 reprend la même lecture sous shrinkage. Le sous-groupe financier, composé de quatre émetteurs, suit un mouvement inverse : sa corrélation augmente entre les deux fenêtres, de 0,65 à 0,69 pour les méthodes de correspondance, de 0,69 à 0,75 pour le maximum de vraisemblance.




FIGURE 3.1 – Corrélations implicites entre paires d'émetteurs, C_0 estimé par la corrélation empirique




FIGURE 3.2 – Corrélations implicites entre paires d'émetteurs, C_0 estimé par shrinkage

3.3 Estimation du DRC

3.3.1 Estimation ponctuelle et intervalle de confiance

Pour chaque actif, on retient PD_k selon sa notation (tableau 3.1, plancher CRR3 de 3 bp appliqué), $LGD_k = 1$, et une exposition $JTD_k = V_0/37$, où V_0 désigne la valeur notionnelle totale du portefeuille. Le seuil de défaut $c_k = \Phi^{-1}(PD_k)$ reprend la définition posée au chapitre 2 (équation (2.3)). Chaque scénario simule $Z \sim \mathcal{N}(0, \Sigma_Z)$ et $\varepsilon_k \sim \mathcal{N}(0, 1)$, puis $X_k = \hat{\beta}_k^\top Z + \hat{\sigma}_k \varepsilon_k$. En posant $V_0 = 1$, la perte simulée s'écrit

$$L = \frac{1}{37} \sum_{k=1}^{37} \mathbb{1}_{X_k < c_k},$$

et le DRC, tel que défini au chapitre 1, est le quantile à 99,9 % de la loi de L :

$$DRC = VaR_{99,9\%}^{1 \text{ an}}(L) = \inf\{q \in \mathbb{R} : \mathbb{P}(L \leq q) \geq 0,999\}.$$

Pour s'assurer de la stabilité du DRC, le superviseur demande d'en fournir un intervalle de confiance à 95 % [European Central Bank, 2025, §128-129]. Le portefeuille étant équipondéré, L ne dépend que du nombre de défauts survenus, non de leur identité : L prend ainsi 38 valeurs distinctes, chacune un multiple de $1/37$, bien que 2^{37} combinaisons d'événements de défaut soient possibles. Une estimation directe de l'intervalle de confiance, en l'absence de connaissance explicite de la distribution de L , s'avère complexe compte tenu de cette discrétisation. Nous retenons l'approche de Dong and Nakayama [2020], dite par sectioning.

Le budget total de M scénarios simulés est divisé en b sections indépendantes de taille égale $m = M/b$. Dans chaque section $\ell = 1, \dots, b$, on calcule le quantile empirique à 99,9 % de L , noté $\widehat{DRC}_\ell$. Le sectioning consiste à centrer l'intervalle de confiance sur l'estimateur calculé directement sur les M scénarios complets¹, noté $\widehat{DRC}_M$. Les b estimations servent uniquement à mesurer la dispersion autour de ce centre,

$$S_b^2 = \frac{1}{b-1} \sum_{\ell=1}^b \left(\widehat{DRC}_\ell - \widehat{DRC}_M \right)^2,$$

et l'intervalle de confiance à $1 - \alpha$ s'écrit

$$\left[\widehat{DRC}_M \pm t_{b-1, \alpha} S_b / \sqrt{b} \right],$$

où $t_{b-1, \alpha}$ désigne le quantile de la loi de Student à $b - 1$ degrés de liberté. Pour les trois périodes de référence, $M = 200\,000$ et $m = 10\,000$, soit $b = 20$ sections. Le niveau de

1. Et non sur la moyenne des b estimations par section comme dans une double boucle de Monte-Carlo, ce qui évite le biais associé à la petite taille d'échantillon m .

confiance retenu est 95 %.

3.3.2 Résultats

La discrétisation de L décrite ci-dessus implique qu'une variation de la structure de corrélation ne modifie le DRC estimé que si elle est suffisante pour faire passer le quantile d'un palier de perte à un autre.

TABLE 3.5 – Estimateur $\widehat{DRC}_M$, $J = 2$ et $J = 3$ (200 000 simulations, sectioning à $b = 20$)

Configuration	Nombre de facteurs	DRC (%)		
		ACP	Frob.	MLE
(1) P1,	2 facteurs	13,51 ± 0,91	13,51 ± 1,08	13,51 ± 0,96
(2) P1-shrunked	3 facteurs	13,51 ± 1,08	13,51 ± 1,08	13,51 ± 1,36
(3) P2,	2 facteurs	10,81 ± 0,96	10,81 ± 0,82	10,81 ± 0,87
(4) P2-shrunked	3 facteurs	10,81 ± 0,96	10,81 ± 1,46	10,81 ± 1,46
(5) P3	2 facteurs	16,21 ± 1,08	16,21 ± 1,36	16,21 ± 1,39
	3 facteurs	16,21 ± 1,16	16,21 ± 1,23	16,21 ± 1,29
(6) P3-shrunked	2 facteurs	13,21 ± 1,08	13,21 ± 1,36	16,21 ± 1,39
	3 facteurs	16,21 ± 1,16	16,21 ± 1,23	16,21 ± 1,29

L'espérance de perte varie peu entre périodes, ce qui est attendu puisqu'elle ne dépend que des probabilités de défaut marginales. Trois constats se dégagent du tableau 3.5 :

- La période covid est celle pour laquelle la structure de corrélation calibrée produit le DRC le plus élevé (16,21 %) sous chacune des configurations testées.
- Le shrinkage ne modifie le DRC estimé que sur la période covid : à $J = 2$, l'ACP et la minimisation de Frobenius passent de 16,21 % sans shrinkage à 13,21 % avec shrinkage, tandis que le maximum de vraisemblance reste à 16,21 % dans les deux cas. À $J = 3$, les trois méthodes retrouvent 16,21 % avec shrinkage, y compris l'ACP et Frobenius.
- Le passage de $J = 2$ à $J = 3$ ne modifie le DRC estimé sur aucune des trois fenêtres de référence, sauf dans le cas (6) P3-shrunked pour l'ACP et Frobenius, où il compense exactement l'effet du shrinkage relevé ci-dessus. Le nombre de facteurs identifié par le critère de ? sur ces trois fenêtres, présenté en Annexe A.2, est

égal à deux, ce qui coïncide avec le nombre de facteurs systémiques prescrit par le régulateur (chapitre 2, section 1.1.2).

Le DRC estimé est identique entre les trois méthodes de calibration pour chaque configuration du tableau 3.5, à l'exception de la période covid sous shrinkage à $J = 2$, où l'ACP et la norme de Frobenius se distinguent du maximum de vraisemblance. Cette identité généralisée résulte de la discrétisation décrite en section 3.3 : le quantile à 99,9 % tombe sur le même palier de défauts pour les trois méthodes dans la quasi-totalité des configurations testées. Elle ne signifie pas que les trois calibrations produisent la même structure de corrélation, le tableau 3.4 rapportant des niveaux différents par secteur.

La largeur de l'intervalle de confiance varie entre méthodes sans direction constante : le maximum de vraisemblance est plus resserré que Frobenius en crise (0,0096 contre 0,0109), et l'inverse se produit sur la période médiane (0,0087 contre 0,0082). Cette absence de direction constante est cohérente avec le fait que S_b est lui-même estimé sur un nombre fini de sections ($b = 20$) et reste, à ce titre, soumis à une variabilité d'échantillonnage propre.

Sur les trois fenêtres de référence, l'écart de DRC entre configurations coïncide avec le choix d'estimateur de C_0 (corrélation empirique ou shrinkage) plutôt qu'avec le choix de méthode de calibration du modèle factoriel, à l'exception du maximum de vraisemblance, insensible à ce choix sur la période covid.

Chapitre 4

Discussion

Les deux chapitres précédents ont établi, d’une part, une distinction théorique entre calibrer un modèle contre une corrélation cible calculée à part et le calibrer directement contre sa vraisemblance (chapitre 2), et d’autre part des résultats empiriques sur un portefeuille de 37 émetteurs du CAC 40 (chapitre 3). Ce chapitre met ces deux volets en regard, en deux temps : l’effet du critère de calibration sur la structure de corrélation reconstruite, puis la traduction de cet effet dans le DRC estimé.

4.1 Le critère de calibration

Le tableau 3.3 confirme, sur les trois fenêtres retenues, que l’ACP itérative et la minimisation de la norme de Frobenius convergent vers une erreur de Frobenius identique à la quatrième décimale. Ce résultat n’est pas propre à ce mémoire : Laurent et al. [2016] l’observent également sur leur propre panel de neuf configurations. Il s’explique directement par la construction des deux méthodes : l’une procède par diagonalisations successives de la matrice de corrélation corrigée de sa diagonale (chapitre 2, section 2.2), l’autre par optimisation sous contrainte du même critère quadratique (section 2.3) ; les deux visent le même objet, la matrice cible C_0 , et y convergent par des voies différentes.

Le maximum de vraisemblance rompt avec cette logique. Il n’ajuste pas les sensibilités contre une cible calculée en amont, mais directement contre la vraisemblance gaussienne du modèle (chapitre 2, équation (2.9)). L’écart de Frobenius qu’il atteint, supérieur de moins de 3 % en relatif à celui des deux autres méthodes dans toutes les configurations testées (tableau 3.3), ne peut être attribué à un artefact numérique : Frobenius et maximum de vraisemblance partagent le même algorithme de résolution, le gradient projeté spectral (section 3.1.3), et ne diffèrent que par la fonction objectif. Cet écart est la signature d’un changement de critère, non d’une différence de mise en œuvre.

Le tableau 3.4 permet de localiser cet écart. Sur le sous-groupe financier, quatre émetteurs sur 37, le maximum de vraisemblance reconstruit systématiquement une corrélation plus élevée que les méthodes de correspondance, sur les trois fenêtres de calibration : 0,69 contre 0,65 en crise 2008, 0,74 contre 0,69 en période médiane, 0,88 contre 0,81 en période covid. Sur le reste du portefeuille, à corrélation moyenne plus faible, les trois méthodes reconstruisent des niveaux quasiment identiques. Cette asymétrie est cohérente avec la géométrie de pénalisation établie au chapitre 2 (section 2.5) : le critère de vraisemblance revient à minimiser la divergence de Kullback-Leibler entre la loi sous C_0 et celle sous

$\Sigma_X(\beta)$ (équation (2.11)), une divergence qui pénalise plus sévèrement une sous-estimation de la corrélation lorsque la cible en porte déjà beaucoup, par le terme $\text{tr}(\Sigma_X(\beta)^{-1}C_0)$, que la norme de Frobenius ne le fait par construction, puisqu'elle traite symétriquement tous les écarts. Le sous-groupe financier, dont la corrélation moyenne dépasse 0,70 sur les trois fenêtres, appartient à la région de la matrice où cette différence de géométrie doit se manifester le plus fortement, comme le montrent les données.

Cette différence de critère n'est cependant pas sans coût théorique. Le chapitre 2 (section 2.4) établit que le domaine du programme de maximum de vraisemblance n'est pas compact, à la différence de celui de Frobenius, et que rien n'exclut en théorie qu'une variance spécifique s'approche de zéro le long des itérations, un cas de Heywood. Cette fragilité potentielle n'a pas été rencontrée sur les configurations testées à $J = 2$ et $J = 3$ (tableau 3.3) : l'algorithme converge dans tous les cas sans que le seuil numérique de protection contre la singularité de $\Sigma_X(\beta)$ ne soit approché. Le ratio entre le nombre de paramètres à estimer et le nombre d'observations, $K \times J/T$, reste dans ces conditions modéré, de 0,28 à $J = 2$ à 0,43 à $J = 3$ sur ce portefeuille ($K = 37$, $T \approx 261$).

Il convient enfin de rappeler la portée exacte de cette comparaison. Le chapitre 2 (section 2.5) établit que ni Frobenius ni le maximum de vraisemblance n'identifient β de façon unique. Les écarts documentés ci-dessus portent donc exclusivement sur la matrice reconstruite, seul objet identifié par les données, et non sur les sensibilités β elles-mêmes, dont l'interprétation économétrique resterait, à ce stade, hors de portée des trois méthodes comparées.

4.2 Le DRC estimé

La perte agrégée L , sur un portefeuille équipondéré de 37 émetteurs, ne prend que 38 valeurs distinctes, chacune un multiple de $1/37$. Le quantile à 99,9 % qui définit le DRC est, de ce fait, constant par paliers : un écart de corrélation entre méthodes de calibration ne se répercute sur le DRC que s'il est suffisant pour faire basculer ce quantile d'un palier à l'autre. Le tableau 3.5 en donne une illustration directe : sur les six configurations testées à $J = 2$ et $J = 3$, le DRC estimé est identique entre les trois méthodes de calibration dans cinq cas sur six. La seule exception, la configuration (6) P3-shrunked à $J = 2$, oppose un DRC de 13,21 % pour l'ACP et Frobenius à un DRC de 16,21 % pour le maximum de vraisemblance. Cette exception se produit précisément sur la fenêtre et le sous-groupe où le constat de la section précédente sur l'écart de corrélation entre les deux paradigmes de calibration est le plus marqué. L'écart de niveau, ordinairement absorbé par la granularité du portefeuille, y est ici suffisant pour déplacer le quantile.

Le tableau 3.4 montre que le shrinkage de C_0 ne modifie la corrélation moyenne reconstruite qu'à la deuxième décimale, conformément à la faible intensité $\hat{\delta}^*$ estimée sur les trois fenêtres (3,7 à 6,0 %, section 2.5). Sur la structure de corrélation elle-même,

l'effet du shrinkage est donc marginal. Il ne l'est pas sur le DRC de la période covid à $J = 2$: l'ACP et Frobenius y passent de 16,21 % sans shrinkage à 13,21 % avec shrinkage, tandis que le maximum de vraisemblance reste à 16,21 % dans les deux cas. L'ajout d'un troisième facteur restaure, pour l'ACP et Frobenius sous shrinkage, un DRC de 16,21 %, identique à celui obtenu sans shrinkage : la capacité supplémentaire du modèle à trois facteurs compense exactement, sur cette configuration, la perte de corrélation induite par le shrinkage.

La figure 4.1 rassemble ces résultats pour les six configurations du tableau 3.2, à $J = 2$ et $J = 3$ facteurs.




FIGURE 4.1 – DRC par méthode de calibration (ACP, Frobenius, maximum de vraisemblance), pour chaque fenêtre de référence, avec et sans shrinkage de C_0 , aux modèles à deux et trois facteurs.

Elle fait apparaître visuellement les deux régularités commentées ci-dessus : l'écart

entre méthodes de calibration reste imperceptible sur cinq des six configurations, et se concentre sur la période covid sous shrinkage à $J = 2$, où le maximum de vraisemblance se distingue de l'ACP et de Frobenius; ce même écart disparaît à $J = 3$.

Ce dernier constat rejoint un résultat obtenu par une voie indépendante des trois méthodes de calibration. Le critère de Marchenko-Pastur [?], qui identifie le nombre de valeurs propres de C_0 excédant le bruit d'échantillonnage attendu sous l'hypothèse d'absence de structure commune ($\lambda^+ = (1 + \sqrt{K/T})^2 \approx 1,90$ pour $K = 37$ et $T \approx 261$), désigne systématiquement $J = 2$ comme nombre de facteurs statistiquement significatif sur les trois fenêtres de calibration. Ce résultat est cohérent avec l'observation, sur ces mêmes fenêtres, qu'un troisième facteur ne modifie le DRC que dans la configuration où il compense un effet du shrinkage, et coïncide avec le nombre de facteurs systémiques prescrit par le régulateur (chapitre 2, section 1.1.2). Il ne s'agit pas d'une validation générale de cette prescription : le critère de Marchenko-Pastur n'a été appliqué qu'aux trois fenêtres de calibration retenues dans ce mémoire, dont la corrélation moyenne reste comprise entre 0,38 et 0,55 (tableau 3.4), et son extension à d'autres régimes de corrélation n'a pas été conduite.

La largeur des intervalles de confiance obtenus par sectioning ne fournit pas, quant à elle, d'indication supplémentaire sur la précision relative des trois méthodes : le maximum de vraisemblance produit un intervalle plus resserré que Frobenius en crise 2008 (0,0096 contre 0,0109), et l'inverse se produit en période médiane (0,0087 contre 0,0082). Cette absence de direction constante est attendue dès lors que l'écart-type S_b est lui-même estimé sur un nombre fini de sections ($b = 20$, chapitre 3, section 3.3) et reste, à ce titre, soumis à sa propre variabilité d'échantillonnage.

4.3 Limites

1. **Granularité du portefeuille.** Le portefeuille de 37 émetteurs rend le DRC ponctuel identique entre les trois méthodes de calibration dans cinq des six configurations testées (section 4.2). L'univers du CAC 40 plafonne à 40 constituants, ce qui limite la possibilité d'élargir le portefeuille pour réduire cette granularité.
2. **Probabilités de défaut et notations.** Les notations de crédit assignées aux 37 émetteurs sont fictives (chapitre 3, section 3.1).
3. **Traitement de Σ_Z et nature des facteurs.** La comparaison a été menée à $\Sigma_Z = I_J$ fixée pour les trois méthodes. Les facteurs retenus sont latents, non-exogènes, ce qui n'autorise pas d'interprétation économique directe des sensibilités calibrées β , du fait de l'indétermination par rotation établie au chapitre 2 (section 2.5).
4. **Hypothèses distributionnelles non testées.** L'hypothèse d'observations indépendantes et identiquement distribuées n'a pas été testée sur les fenêtres retenues,

et aucune procédure d'identification de la période de tension, comparable à celle prescrite par la CRR3 pour le risque de marché général, n'a été appliquée à la calibration des corrélations de défaut.

4.4 Perspectives

1. Appliquer la méthodologie de calibration par maximum de vraisemblance en présence de facteurs exogènes. Nous pourrions nous inspirer du travail de [Laurent et al. \[2016\]](#) pour la construction de ces facteurs exogènes à l'aide d'indices boursiers globaux et régionaux.
2. Reprendre la méthodologie présentée sur un portefeuille plus granulaire.
3. Estimer Σ_Z conjointement à β .

Conclusion générale

Une hypothèse implicite traverse une partie de la littérature sur la modélisation du DRC : celle selon laquelle le choix de la méthode de calibration serait secondaire dès lors que le cadre théorique retenu, un modèle gaussien multifactoriel, est correctement posé. Ce travail en propose une lecture plus nuancée, à partir de trois méthodes de calibration comparées sur un portefeuille de 37 émetteurs du CAC 40 : l'ACP itérative, la minimisation de la norme de Frobenius, et le maximum de vraisemblance du modèle, cette dernière approche constituant, à notre connaissance, un apport nouveau à la modélisation du DRC.

L'ACP itérative et la minimisation de Frobenius convergent, sans surprise, vers un ajustement identique : les deux méthodes minimisent le même critère par des voies distinctes (chapitre 2). Le maximum de vraisemblance rompt avec cette logique de correspondance à une cible calculée à part. L'écart qu'il produit, modeste en moyenne, moins de 3 % en écart relatif de Frobenius sur les configurations testées, n'est pas pour autant négligeable : il se concentre presque intégralement sur le sous-groupe des émetteurs financiers, dont la corrélation implicite dépasse 0,70, une conséquence directe de la géométrie de pénalisation propre à la divergence de Kullback–Leibler, à laquelle le critère de vraisemblance est mathématiquement équivalent (chapitre 2, section 2.5 ; chapitre 4, section 4.1).

Cette même géométrie explique une propriété plus opérationnelle, mise en évidence au chapitre 4 (section 4.2) : le maximum de vraisemblance reste insensible au choix de l'estimateur de la corrélation empirique, brut ou shrinké, là où l'ACP et Frobenius y sont sensibles. C'est cette différence qui produit l'unique écart observé sur le DRC ponctuel parmi les six configurations testées, sur la période de crise sanitaire 2020-2021. Sur ce portefeuille de 37 émetteurs, la perte agrégée ne prend que 38 valeurs possibles : un écart de corrélation, même réel, ne se répercute sur le DRC que s'il suffit à déplacer ce quantile discret d'un palier à l'autre. Un dispositif de validation qui ne s'appuierait que sur le DRC ponctuel peut ainsi rester silencieux face à des différences de calibration pourtant réelles et mesurables sur la matrice de corrélation elle-même. Un critère indépendant des trois méthodes comparées, celui de Marchenko-Pastur, vient corroborer cette lecture : il désigne deux facteurs comme statistiquement significatifs sur les trois fenêtres de calibration retenues, un nombre qui coïncide avec celui que prescrit la réglementation, sans que cette coïncidence ait été recherchée a priori.

Ces résultats restent circonscrits aux trois fenêtres de calibration retenues par convention dans ce travail, crise de 2008, période médiane 2013-2014 et crise sanitaire 2020-2021, faute d'avoir mis en œuvre la procédure d'identification de la période de tension que le

texte réglementaire prescrit pour le risque de marché général.

L'implication pratique de ces résultats dépasse le seul choix entre trois méthodes de calibration. Elle porte sur ce qu'une politique de validation doit surveiller pour rendre compte fidèlement de l'effet d'une méthode de calibration : non pas la matrice de corrélation dans son ensemble, où les écarts entre méthodes restent souvent imperceptibles, mais les blocs d'émetteurs les plus corrélés, où ils se concentrent, et la robustesse de cette calibration à des choix méthodologiques annexes, comme l'estimation de la cible elle-même, plutôt que le seul DRC ponctuel, dont la granularité peut masquer des différences par ailleurs réelles.

Bibliographie

- Leif Andersen, Jakob Sidenius, and Sanjiv Basu. All your hedges in one basket. *Risk Magazine*, 16(11) :67–72, 2003.
- BCBS. Revisions to the basel ii market risk framework. Technical report, Bank for International Settlements, July 2009a. Distinct de bcbs2009b (même année, même auteur collectif) : convention plainnat.
- BCBS. Guidelines for computing capital for incremental risk in the trading book. Technical report, Bank for International Settlements, July 2009b. Distinct de bcbs2009a (même année, même auteur collectif) : convention plainnat.
- BCBS. Minimum capital requirements for market risk. Technical report, Bank for International Settlements, 2016.
- BCBS. Minimum capital requirements for market risk. Technical report, Bank for International Settlements, 2019.
- Ernesto G. Birgin, José Mario Martínez, and Marcos Raydan. Algorithm 813 : SPG – software for convex-constrained optimization. *ACM Transactions on Mathematical Software*, 27(3) :340–349, 2001.
- Rüdiger Borsdorf, Nicholas J. Higham, and Marcos Raydan. Computing a nearest correlation matrix with factor structure. *SIAM Journal on Matrix Analysis and Applications*, 31(5) :2603–2622, 2010.
- Hui Dong and Marvin K. Nakayama. A tutorial on quantile estimation via Monte Carlo. In Bruno Tuffin and Pierre L’Ecuyer, editors, *Monte Carlo and Quasi-Monte Carlo Methods*, volume 324 of *Springer Proceedings in Mathematics & Statistics*. Springer, Cham, 2020.
- European Central Bank. ECB guide to internal models – market risk. Technical report, European Central Bank, 2025.
- European Commission. Capital requirements regulation 3 (crr3), 2024.
- Harry H. Harman. *Modern Factor Analysis*. University of Chicago Press, 3rd edition, 1976.
- Angelo D. Joseph. Emerging market default risk charge model. *Journal of Risk and Financial Management*, 16(3) :194, 2023. doi : 10.3390/jrfm16030194.

- Jean-Paul Laurent, Michael Sestier, and Stéphane Thomas. Trading book and credit risk : How fundamental is the Basel review? *Journal of Banking & Finance*, 73 :211–223, 2016. doi : 10.1016/j.jbankfin.2016.07.002.
- D. N. Lawley. The estimation of factor loadings by the method of maximum likelihood. *Proceedings of the Royal Society of Edinburgh*, 60 :64–82, 1940.
- Olivier Ledoit and Michael Wolf. Improved estimation of the covariance matrix of stock returns with an application to portfolio selection. *Journal of Empirical Finance*, 10(5) :603–621, 2003. ISSN 0927-5398. doi : [https://doi.org/10.1016/S0927-5398\(03\)00007-0](https://doi.org/10.1016/S0927-5398(03)00007-0). URL <https://www.sciencedirect.com/science/article/pii/S0927539803000070>.
- Robert C. Merton. On the pricing of corporate debt : The risk structure of interest rates. *The Journal of Finance*, 29(2) :449–470, 1974. doi : 10.2307/2978814.
- Michael Pykhtin. Multi-factor adjustment. *Risk Magazine*, 17(3) :85–90, 2004.
- Mohamed Jaouad Slime. Mathematical modeling of concentration risk under the default risk charge. *Journal of Probability and Statistics*, 2022. doi : 10.1155/2022/3063505.
- L. L. Thurstone. *Multiple-Factor Analysis*. University of Chicago Press, 1947.
- Oldrich A. Vasicek. Loan portfolio value. *Risk Magazine*, 15(12) :160–162, 2002.
- Sascha Wilkens and Mirela Predescu. Default risk charge : Modelling framework for the "Basel" risk measure. *Journal of Risk*, 15 :23–50, 2016.

Annexe A

Annexes

A.1 Compléments théoriques

Cette annexe complète le chapitre 2 sur trois points. La section A.1.1 présente le gradient projeté spectral (SPG), solveur générique commun aux deux critères d’optimisation retenus dans ce mémoire. Les sections A.1.2 et A.1.3 démontrent les formes explicites des gradients présentés dans ce document ainsi que le lien entre le critère de maximum de vraisemblance et la divergence de Kullback–Leibler.

On reprend les notations du chapitre 2. $D(\beta) = \text{diag}(\sigma_1^2(\beta), \dots, \sigma_K^2(\beta))$ avec $\sigma_k^2(\beta) = 1 - \beta_k^\top \Sigma_Z \beta_k$, et $\Sigma_X(\beta) = \beta \Sigma_Z \beta^\top + D(\beta)$. Les observations $(X_1, \dots, X_T)$ sont indépendantes et identiquement distribuées, chaque X_t suivant la loi $\mathcal{N}(0, \Sigma_X(\beta))$. On note $\mathcal{O}_k = \{\beta_k \in \mathbb{R}^J : \beta_k^\top \Sigma_Z \beta_k < 1\}$ le domaine admissible ouvert de la k -ième ligne de β .

A.1.1 Le solveur SPG

Algorithm 2 Gradient projeté spectral (SPG) [Birgin et al., 2001]

```

1: procedure SPG( $f, \nabla f, \Omega, \beta^{(0)}, \text{tol}$ )
2:    $\lambda_0 \leftarrow 1$  ▷ pas spectral initial
3:    $i \leftarrow 0$ 
4:   repeat
5:      $g_i \leftarrow \nabla f(\beta^{(i)})$ 
6:      $d_i \leftarrow \text{Proj}_\Omega(\beta^{(i)} - \lambda_i g_i) - \beta^{(i)}$  ▷ direction de descente projetée
7:     Choisir  $\alpha_i \in (0, 1]$  par une recherche linéaire non monotone de Grippo–
       Lampariello–Lucidi, de sorte que
       
$$f(\beta^{(i)} + \alpha_i d_i) \leq \max_{0 \leq j \leq \min(i, M)} f(\beta^{(i-j)}) + \gamma \alpha_i g_i^\top d_i$$

       pour une constante  $\gamma \in (0, 1)$  et une fenêtre de mémoire  $M$  fixées a priori
8:      $\beta^{(i+1)} \leftarrow \beta^{(i)} + \alpha_i d_i$ 
9:      $s_i \leftarrow \beta^{(i+1)} - \beta^{(i)}, \quad y_i \leftarrow \nabla f(\beta^{(i+1)}) - g_i$ 
10:     $\lambda_{i+1} \leftarrow \frac{s_i^\top s_i}{s_i^\top y_i}$  si  $s_i^\top y_i > 0$ , sinon  $\lambda_{i+1} \leftarrow \lambda_{\max}$  ▷ pas de Barzilai–Borwein
11:     $i \leftarrow i + 1$ 
12:  until  $\|\text{Proj}_\Omega(\beta^{(i)} - g_i) - \beta^{(i)}\| < \text{tol}$ 
13:  return  $\hat{\beta} \leftarrow \beta^{(i)}$ 
14: end procedure
    
```

Projection sur le domaine admissible. Pour les deux applications retenues dans ce mémoire, Ω (ou son relâché Ω_ε) est une intersection de K ellipsoïdes indépendants, un par ligne de β . La projection euclidienne $\text{Proj}_\Omega(\beta)$ se calcule donc ligne par ligne, à faible coût. Dans le cas $\Sigma_Z = I_J$ retenu au chapitre 2, chaque ellipsoïde est la boule unité (ou une boule légèrement rétractée pour Ω_ε) de $\mathbb{R}^J$, et la projection admet la forme close suivante : si $\beta_k^\top \beta_k \leq 1$ (respectivement $\leq 1 - \varepsilon$), la ligne reste inchangée ; sinon,

$$\left(\text{Proj}_\Omega(\beta)\right)_k = \frac{\beta_k}{\sqrt{\beta_k^\top \beta_k}} \quad \left(\text{respectivement } \sqrt{1 - \varepsilon} \frac{\beta_k}{\sqrt{\beta_k^\top \beta_k}}\right).$$

C'est cette structure séparable ligne par ligne qui rend l'algorithme SPG praticable même pour un grand nombre d'actifs K [Birgin et al., 2001].

A.1.2 Critère de la distance de Frobenius

Proposition A.1 (Gradient du critère de Frobenius). *On pose $f(\beta) = \|C_0 - \Sigma_X(\beta)\|_F^2 = \text{tr}((C_0 - \Sigma_X(\beta))^\top (C_0 - \Sigma_X(\beta)))$, avec $\Sigma_X(\beta) := \beta \Sigma_Z \beta^\top + \text{diag}(\mathbf{1} - \text{diag}(\beta \Sigma_Z \beta^\top))$, alors*

$$\nabla f(\beta) = 4(\Sigma_X(\beta) - C_0) \beta \Sigma_Z.$$

Démonstration. Posons $A(\beta) := \beta \Sigma_Z \beta^\top$, $D(\beta) := \text{diag}(\text{diag}(A(\beta)))$ et $R(\beta) := C_0 - \Sigma_X(\beta) = C_0 - A(\beta) + D(\beta) - I_K$.

Étape 1 : Le résidu diagonal est identiquement nul. Pour tout k ,

$$R_{kk}(\beta) = (C_0)_{kk} - [A(\beta)_{kk} - D(\beta)_{kk} + 1] = (C_0)_{kk} - 1 = 0,$$

puisque $D(\beta)_{kk} = A(\beta)_{kk}$ par construction et $(C_0)_{kk} = 1$ par hypothèse. La diagonale de $R(\beta)$ est donc nulle quel que soit β , et $R(\beta)$, différence de matrices symétriques, est elle-même symétrique. On peut donc écrire simplement $f(\beta) = \text{tr}(R(\beta)^2)$.

Étape 2 : Différentielle de f . En utilisant $d \text{tr}(R^2) = 2 \text{tr}(R dR)$ (valide car $R^\top = R$) et $dR = -dA + dD$ (car $dC_0 = 0$, $dI_K = 0$),

$$df = 2 \text{tr}(R(-dA + dD)) = -2 \text{tr}(R dA) + 2 \text{tr}(R dD).$$

Étape 3 : Le terme diagonal disparaît. Comme R est symétrique et dD diagonale,

$$\text{tr}(R dD) = \sum_k R_{kk} dD_{kk} = 0$$

d'après l'étape 1, ce terme s'annule *entièrement*, quelle que soit la valeur de dD .

Étape 4 : Différentiation du terme restant. Avec $dA = d\beta \Sigma_Z \beta^\top + \beta \Sigma_Z d\beta^\top$, et par cyclicité de la trace jointe à la symétrie de R et de Σ_Z ,

$$\text{tr}(R dA) = \text{tr}(R d\beta \Sigma_Z \beta^\top) + \text{tr}(R \beta \Sigma_Z d\beta^\top) = 2 \text{tr}((R \beta \Sigma_Z)^\top d\beta),$$

les deux termes étant égaux car $\text{tr}(R \beta \Sigma_Z d\beta^\top) = \text{tr}(d\beta \Sigma_Z \beta^\top R) = \text{tr}(R d\beta \Sigma_Z \beta^\top)$ par symétrie de R .

Conclusion. En combinant les Étapes 2 à 4,

$$df = -4 \text{tr}((R \beta \Sigma_Z)^\top d\beta) = 4 \text{tr}(((\Sigma_X(\beta) - C_0) \beta \Sigma_Z)^\top d\beta),$$

et par identification dans $df = \text{tr}(\nabla f(\beta)^\top d\beta)$, on obtient $\nabla f(\beta) = 4(\Sigma_X(\beta) - C_0) \beta \Sigma_Z$. $\square$

A.1.3 Critère du maximum de vraisemblance

Gradient de la log-vraisemblance des données observées

Proposition A.2 (Gradient de la log-vraisemblance). *On pose $\ell(\beta) = -\frac{T}{2} \left[K \log(2\pi) + \log |\Sigma_X(\beta)| + \text{tr}(\Sigma_X(\beta)^{-1} C_0) \right]$, avec $C_0 := \frac{1}{T} \sum_{t=1}^T X_t X_t^\top$, alors*

$$\nabla \ell(\beta) = T \left[\Sigma_X(\beta)^{-1} (C_0 - \Sigma_X(\beta)) \Sigma_X(\beta)^{-1} \right]_{\text{off}} \beta \Sigma_Z,$$

où $[\cdot]_{\text{off}}$ est l'opérateur annulant la diagonale de la matrice argument.

Démonstration. Posons $M(\beta) := \Sigma_X(\beta)^{-1} (C_0 - \Sigma_X(\beta)) \Sigma_X(\beta)^{-1}$, symétrique comme produit et différence de matrices symétriques encadrées de part et d'autre par $\Sigma_X(\beta)^{-1}$.

Étape 1 : Différentielles du log-déterminant et de la trace. Pour Σ symétrique inversible, $d \log |\Sigma| = \text{tr}(\Sigma^{-1} d\Sigma)$ et, via $d(\Sigma^{-1}) = -\Sigma^{-1} (d\Sigma) \Sigma^{-1}$, on obtient

$$d \text{tr}(\Sigma^{-1} C_0) = -\text{tr}(\Sigma^{-1} (d\Sigma) \Sigma^{-1} C_0) = -\text{tr}(\Sigma^{-1} C_0 \Sigma^{-1} d\Sigma)$$

par cyclicité de la trace. En combinant, $d\ell = \frac{T}{2} \text{tr}(M(\beta) d\Sigma_X)$.

Étape 2 : Le terme diagonal disparaît. Comme à la Proposition A.1, écrivons $\Sigma_X(\beta) = A(\beta) - D(\beta) + I_K$ avec $A(\beta) = \beta \Sigma_Z \beta^\top$, $D(\beta) = \text{diag}(\text{diag}(A(\beta)))$, si bien que $d\Sigma_X = dA - dD$. La symétrie de M et la diagonalité de dD donnent $\text{tr}(M dD) = \text{tr}(M_{\text{diag}} dA)$ avec $M_{\text{diag}} := \text{diag}(\text{diag}(M))$, d'où

$$\text{tr}(M d\Sigma_X) = \text{tr}(M dA) - \text{tr}(M_{\text{diag}} dA) = \text{tr}(M_{\text{off}} dA), \quad M_{\text{off}} := M - M_{\text{diag}}.$$

Étape 3 : Différentiation par rapport à β . Exactement comme à l'Étape 4 de la preuve de la Proposition A.1, avec $dA = d\beta \Sigma_Z \beta^\top + \beta \Sigma_Z d\beta^\top$ et la symétrie de M_{off} et Σ_Z ,

$$\text{tr}(M_{\text{off}} dA) = 2 \text{tr}((M_{\text{off}} \beta \Sigma_Z)^\top d\beta).$$

Conclusion. $d\ell = T \text{tr}((M_{\text{off}} \beta \Sigma_Z)^\top d\beta)$, d'où le résultat par identification. $\square$

Lien avec la divergence de Kullback–Leibler

Lemme A.1 (Divergence de Kullback–Leibler entre deux lois gaussiennes centrées). *Pour Σ_0, Σ_1 symétriques définies positives de taille K ,*

$$D_{\text{KL}}(\mathcal{N}(0, \Sigma_0) \parallel \mathcal{N}(0, \Sigma_1)) = \frac{1}{2} \left[\text{tr}(\Sigma_1^{-1} \Sigma_0) - K + \log |\Sigma_1| - \log |\Sigma_0| \right].$$

Démonstration. Par définition, $D_{\text{KL}}(p_0 \parallel p_1) = \mathbb{E}_{p_0}[\log p_0(X) - \log p_1(X)]$ pour $X \sim \mathcal{N}(0, \Sigma_0)$.

En développant les deux log-densités gaussiennes centrées,

$$\log p_0(X) - \log p_1(X) = \frac{1}{2} \left[\log |\Sigma_1| - \log |\Sigma_0| + X^\top \Sigma_1^{-1} X - X^\top \Sigma_0^{-1} X \right].$$

Sous p_0 , $\mathbb{E}[X^\top \Sigma_1^{-1} X] = \text{tr}(\Sigma_1^{-1} \Sigma_0)$ et $\mathbb{E}[X^\top \Sigma_0^{-1} X] = \text{tr}(\Sigma_0^{-1} \Sigma_0) = K$. En reportant,

$$D_{\text{KL}}(p_0 \| p_1) = \frac{1}{2} \left[\log |\Sigma_1| - \log |\Sigma_0| + \text{tr}(\Sigma_1^{-1} \Sigma_0) - K \right]. \quad \square$$

Proposition A.3 (Vraisemblance observée et divergence de Kullback–Leibler).

$$\ell(\beta) = -T \cdot D_{\text{KL}}(\mathcal{N}(0, C_0) \| \mathcal{N}(0, \Sigma_X(\beta))) - \frac{T}{2} (K + \log |C_0|) - \frac{TK}{2} \log(2\pi).$$

Démonstration. Appliquons le Lemme A.1 avec $\Sigma_0 = C_0$, $\Sigma_1 = \Sigma_X(\beta)$:

$$-T \cdot D_{\text{KL}}(\mathcal{N}(0, C_0) \| \mathcal{N}(0, \Sigma_X(\beta))) = -\frac{T}{2} \left[\text{tr}(\Sigma_X(\beta)^{-1} C_0) - K + \log |\Sigma_X(\beta)| - \log |C_0| \right].$$

En comparant terme à terme avec l'expression rappelée de $\ell(\beta)$, les termes en $\text{tr}(\Sigma_X(\beta)^{-1} C_0)$ et $\log |\Sigma_X(\beta)|$ coïncident exactement, à l'exception des termes indépendants de β qu'il reste à regrouper :

$$\ell(\beta) + T \cdot D_{\text{KL}}(\dots) = -\frac{TK}{2} \log(2\pi) + \frac{T}{2} [-K + \log |C_0|] \cdot (-1) = -\frac{T}{2} (K + \log |C_0|) - \frac{TK}{2} \log(2\pi),$$

ce qui est bien la constante annoncée. $\square$

C'est cette identité qui justifie la lecture du critère de maximum de vraisemblance comme une minimisation de divergence de Kullback–Leibler entre C_0 et $\Sigma_X(\beta)$, par opposition à la norme de Frobenius (Proposition A.1) : les deux gradients partagent la même structure de preuve, mais non la même géométrie de pénalisation, comme discuté à la section 2.5.

A.2 Résultats empiriques complémentaires




FIGURE A.1 – Corrélation moyenne (modèle à 2 facteurs), C_0 estimé par corrélation empirique (haut) et par shrinkage (bas) sur différentes périodes.




FIGURE A.2 – DRC, modèle à 2 facteurs, C_0 estimé par corrélation empirique (haut) et par shrinkage (bas) sur différentes périodes.




FIGURE A.3 – Corrélation moyenne (modèle à 3 facteurs), C_0 estimé par corrélation empirique (haut) et par shrinkage (bas) sur différentes périodes.




FIGURE A.4 – DRC, modèle à 3 facteurs, C_0 estimé par corrélation empirique (haut) et par shrinkage (bas) sur différentes périodes.